

Funcionamiento de la NGS (Secuenciación de Nueva Generación)

Alumno: Josue Samuel Philco Puma

28 de abril de 2026

1. Introducción

La secuenciación del ADN es una herramienta fundamental para la comprensión de la información genética de los organismos. Sin embargo, actualmente los métodos tradicionales, como la **Secuenciación de Sanger**, eran limitados en velocidad y en capacidad de procesamiento. Con el avance biotecnológico surge lo que es la **Secuenciación de Nueva Generación (NGS)**, un conjunto de tecnologías que permiten determinar el orden de millones de fragmentos de ADN o ARN simultáneamente [1].

A diferencia de los métodos clásicos, el **NGS** se basa en el principio de **Secuenciación Masiva en Paralelo**, permitiendo analizar grandes volúmenes de información genética en menor tiempo y con un menor costo. En este contexto, vamos a abordar el funcionamiento del **NGS** desde una perspectiva tanto biológica como computacional, sobretodo en la generación, representación y procesamiento de los datos, así como los principales desafíos [2].

2. Definición del NGS

Este es una tecnología de secuenciación masivamente paralela que ofrece un alto rendimiento, escalabilidad y velocidad ultraaltos. Esta tecnología es utilizada para determinar el orden de los nucleótidos en genomas completos o en regiones específicas del ADN o ARN, el uso de esta tecnología ha revolucionado las ciencias biológicas permitiendo realizar una amplia variedad de aplicaciones y estudiar sistemas biológicos a un nivel nunca antes alcanzado [3].

En un enfoque computacional, el **NGS** constituye una técnica experimental que va a permitir estudiar el material genético de los organismos, lo que facilita la identificación de genes, mutaciones y variantes genómicas en diferentes contextos, como las enfermedades o procesos evolutivos [4].

En conjunto, el **NGS** puede entenderse como una tecnología interdisciplinaria que integra procesos biológicos de secuenciación con técnicas computacionales avanzadas para el análisis de datos genómicos a gran escala.

3. Funcionamiento del NGS

Ahora que tenemos una base a lo que es la **Secuenciación de Nueva Generación**, debemos analizar como es que este funciona, tanto de forma biológica como de manera computacional. Este proceso lo vamos a dividir de la siguiente manera:

3.1. Preparación de la muestra

Iniciamos con la extracción y purificación del ADN/ARN de una muestra biológica como células, tejidos, etc. Se lisan las células para que se puedan liberar los ácidos nucleicos, y luego separar el ADN/ARN de las proteínas y contaminantes. Con el ADN purificado, se va a precipitar y resuspender en un buffer, midiendo su concentración y pureza, esto es esencial para la evaluación de calidad con espectrofotometría o fluorometría, pues los ácidos nucleicos de una buena calidad van a tener resultados más confiables [1].

Una vez que se obtiene un ADN de calidad, se va a proceder a preparar la librería de secuenciación para transformarlo en fragmentos aptos para el secuenciador [5].

1. Primero se fragmenta el ADN en pedazos cortos (típicamente 100–300 pb) mediante métodos físicos (por ejemplo sonicación o nebulización) o enzimáticos.

2. Se llevan operaciones de reparación de extremos y se ligan adaptadores cortos en los extremos. Estos adaptadores contienen secuencias conocidas para ampliar y fijar los fragmentos al flujo de secuenciación.
3. Finalmente la librería se cuantifica y en caso de ser necesario se amplifica por PCR (enriquecimiento en regiones de interés). Es importante maximizar la complejidad de la librería para que represente fielmente la muestra inicial, minimizando sesgos introducidos durante la preparación.

3.2. Fragmentación y secuenciación

Para la etapa de secuenciación, los fragmentos de ADN se van a fijar en una superficie sólida y amplificar localmente para formar agrupaciones de copias idénticas llamadas **clusters** [1]. Existen plataformas que realizan esta operación, por ejemplo:

- **Illumina** para formar las agrupaciones se hibrida en un *flow cell* y se replica mediante PCR, lo que genera clusters que van a contener miles de copias clonales del mismo fragmento. Esto aumenta la señal para la detección óptica.
 1. Se ejecuta la secuenciación por síntesis (SBS): durante cada ciclo se incorporan cuatro nucleótidos modificados con terminadores reversibles y fluoróforos [6].
 2. Al añadir un dNTP, su fluoróforo se detecta mediante láser y cámara; luego el terminador y fluoróforo se eliminan para continuar el ciclo.
 3. La señal óptica de cada ciclo se traduce directamente en la base correspondiente, lo que conduce a lecturas de alta precisión.
- **Oxford Nanopore** deja pasar la molécula de ADN completa a través de un nanoporo insertado en una membrana. A medida que las bases atraviesan el poro, se registra un cambio en la corriente eléctrica que es característica de cada base. Así se leen directamente secuencias extremadamente largas (varias decenas de kb, incluso más de 100 kb) en tiempo real.
- **PacBio SMRT** con una ADN polimerasa lee moléculas largas circularizadas en pozos de reacción (*zero-mode waveguides*), incorporando nucleótidos marcados en tiempo real. PacBio produce lecturas medias en el rango de 10–25 kb. Su precisión por lectura es moderada (~90 % de acierto por base), pero mediante secuencias múltiples del mismo fragmento (método HiFi) el consenso final alcanza >99 % de exactitud [7].

3.3. Generación, representación y formato de datos

Tras la secuenciación, el instrumento realiza la *base calling* para convertir las señales crudas en secuencias de nucleótidos. El resultado inicial son millones de lecturas (*reads*) cortas almacenadas en archivos FASTQ, donde cada entrada contiene la secuencia nucleotídica y una línea de puntuaciones de calidad (*Phred score*) por base [1]. Estas puntuaciones indican la probabilidad de error de cada base; por ejemplo, Q30 $\approx$ 99.9 % de probabilidad de acierto. Los archivos FASTQ resultantes pueden ocupar decenas o cientos de gigabytes: un genoma humano secuenciado a profundidad 30 $\times$ genera típicamente ~100–200 GB.

En las fases posteriores, las lecturas se procesan computacionalmente. Al alinear cada *read* contra un genoma de referencia, las posiciones y discrepancias se registran en archivos SAM (texto plano) o BAM (su versión binaria comprimida), los cuales almacenan la ubicación genómica de cada lectura, la calidad del alineamiento y otros metadatos asociados. Una vez identificadas las variantes genéticas, los resultados se anotan en archivos VCF (*Variant Call Format*), que resume SNPs, indels y otras variantes respecto al genoma de referencia, junto con información de calidad y anotaciones funcionales [1].

En conjunto, un experimento de NGS produce principalmente tres tipos de archivos:

- **FASTQ**: lecturas crudas con puntuaciones de calidad por base.
- **SAM/BAM**: lecturas alineadas contra el genoma de referencia.
- **VCF**: variantes genéticas detectadas y anotadas.

A estos se suman los metadatos de la corrida (protocolos, índices de muestra, estadísticas de rendimiento). El volumen total es masivo: un único experimento puede generar fácilmente terabytes de información, lo que exige almacenamiento especializado y sistemas de archivos de alto rendimiento.

3.4. Procesamiento computacional

El análisis de datos NGS sigue típicamente un *pipeline* de bioinformática estructurado en varias etapas sucesivas.

1. **Control de calidad y preprocesamiento.** Antes de cualquier análisis, se evalúa la calidad de los archivos FASTQ con herramientas como FastQC o MultiQC. A continuación se eliminan lecturas de baja calidad y adaptadores residuales mediante Trimmomatic o Cutadapt, lo que mejora la confiabilidad de todos los pasos posteriores.
2. **Alineamiento (*read mapping*).** Las lecturas filtradas se mapean contra un genoma de referencia usando alineadores eficientes para lecturas cortas, como BWA o Bowtie2. Estos programas indexan el genoma mediante estructuras basadas en la Transformada de Burrows-Wheeler y el FM-Index, lo que reduce considerablemente el uso de memoria; Bowtie2, por ejemplo, indexa el genoma humano con apenas ~3.2 GB de RAM y admite alineamiento multihilo. El resultado es un archivo SAM/-BAM con las posiciones encontradas para cada *read*. Para datos de RNA-Seq existen alineadores especializados en lecturas fusionadas, como HISAT2 o STAR [8].
3. **Ensamblaje de secuencias.** Cuando no se dispone de un genoma de referencia adecuado, se recurre al ensamblaje *de novo*. Los algoritmos fragmentan las lecturas en *k*-mers y construyen grafos de De Bruijn, donde cada nodo representa un *k*-mer y los arcos indican solapamientos, para recomponer la secuencia original. Herramientas como Velvet, SPAdes o MEGAHIT implementan este enfoque, aunque resulta computacionalmente exigente en términos de memoria para genomas grandes. Como alternativa, el ensamblaje guiado por referencia aprovecha un genoma conocido para simplificar la reconstrucción y reducir la complejidad algorítmica.
4. **Detección de variantes (*variant calling*).** A partir del alineamiento se identifican diferencias respecto al genoma de referencia. GATK, samtools y bcftools realizan un análisis estadístico sobre las lecturas alineadas para llamar SNPs, indels y variantes estructurales, exportando los resultados en formato VCF con anotaciones de calidad. En esta etapa se aplican filtros y recalibraciones para minimizar falsos positivos. El VCF final sirve de punto de partida para análisis ulteriores: anotación génica, predicción funcional y comparaciones poblacionales, entre otros [1].

3.5. Problemas computacionales y desafíos

El análisis NGS plantea una serie de desafíos informáticos que conviene considerar en conjunto.

1. **Volumen de datos y escalabilidad.** Desde 2008, la capacidad de generación de datos de los secuenciadores ha crecido a un ritmo muy superior al previsto por la Ley de Moore: los equipos modernos producen terabytes en cuestión de horas. Esto obliga a disponer de infraestructuras de alto rendimiento — clústeres de cómputo o plataformas en la nube — y a diseñar algoritmos capaces de aprovechar la paralelización. Herramientas como Bowtie2 y BWA distribuyen el alineamiento entre múltiples núcleos de CPU, mientras que el ensamblaje *de novo* exige grandes reservas de memoria [9].
2. **Calidad de lecturas y sesgos sistemáticos.** Ninguna plataforma está libre de errores propios. En Illumina SBS la tasa de error por base es baja (<0.1 %) y de naturaleza aleatoria, aunque pueden aparecer sesgos de cobertura en regiones con contenido GC extremo. Nanopore acumula errores con mayor frecuencia, sobre todo en homopolímeros y motivos de secuencia complejos. PacBio presenta una tasa de error inicial cercana al 10 %, que se corrige mediante el consenso HiFi. A todo ello se suma el sesgo introducido por la amplificación por PCR durante la preparación de librerías, que puede distorsionar la representación de ciertas regiones. Estos factores complican el ensamblaje y la detección de variantes, especialmente en zonas repetitivas del genoma [3].
3. **Cobertura y regiones repetitivas.** Las lecturas cortas tienen dificultades para resolver repeticiones largas, lo que puede dejar huecos en el ensamblaje. Incluso con lecturas largas, cubrir genomas grandes de forma uniforme sigue siendo complejo: la identificación de polimorfismos estructurales

extensos, por ejemplo, puede resultar imprecisa cuando las lecturas no abarcan la región completa. Se requieren por tanto algoritmos específicos que manejen caídas de cobertura y secuencias repetitivas sin introducir artefactos.

4. **Requerimientos de memoria y tiempo de cómputo.** Construir los grafos de De Bruijn necesarios para ensamblar genomas eucariotas puede consumir decenas de gigabytes de memoria. Aunque el uso del FM-Index mantiene la huella de memoria del alineamiento relativamente contenida — Bowtie2 indexa el genoma humano con ~3.2 GB — el ensamblaje *de novo* sigue siendo intensivo en recursos. El llamado de variantes, con etapas de realineamiento local y recalibración de calidad, puede prolongarse horas o días según el tamaño del conjunto de datos. La gestión de archivos de gran tamaño (FASTQ de cientos de gigabytes, archivos BAM) añade retos adicionales de almacenamiento y rendimiento de entrada/salida.
5. **Reproducibilidad y estandarización.** Un *pipeline* NGS integra múltiples herramientas y parámetros, lo que hace que la reproducibilidad entre laboratorios o corridas no esté garantizada. Los formatos estándar — FASTQ, SAM/BAM y VCF — facilitan la interoperabilidad, pero las versiones de software y las configuraciones específicas pueden variar significativamente. Para mitigar esto se recomienda documentar los flujos de trabajo con sistemas como Snakemake o Nextflow, encapsular los entornos de ejecución en contenedores (Docker o Singularity) y aplicar procedimientos de validación que garanticen resultados consistentes independientemente del sistema donde se ejecute el análisis.

4. Conclusiones

En conclusión, la secuenciación de nueva generación (NGS) es una tecnología fundamental que integra procesos biológicos y computacionales para analizar material genético a gran escala. Biológicamente, posibilita obtener información detallada del ADN a través de etapas como la preparación de muestras, la fragmentación y la secuenciación masiva en paralelo. Por otra parte, desde una perspectiva computacional, implica el manejo de grandes cantidades de datos que deben ser procesados, representados y analizados mediante algoritmos específicos para tareas como el alineamiento, ensamblaje y detección de variantes. Esta combinación de disciplinas convierte al NGS en una herramienta esencial de la bioinformática moderna, transformando datos de secuenciación en conocimiento útil para la investigación científica y las aplicaciones médicas.

Referencias

- [1] Thermo Fisher Scientific. *What is Next-Generation Sequencing (NGS)?* Disponible en: <https://www.thermofisher.com/pe/en/home/life-science/sequencing/sequencing-learning-center/next-generation-sequencing-information/ngs-basics/what-is-next-generation-sequencing.html> (Accedido: 23 de abril de 2026).
- [2] National Cancer Institute. *NGS (Next-Generation Sequencing)*. Disponible en: <https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/ngs> (Accedido: 23 de abril de 2026).
- [3] Illumina. *Next-Generation Sequencing (NGS) | Explore the technology*. Disponible en: <https://www.illumina.com/science/technology/next-generation-sequencing.html> (Accedido: 26 de abril de 2026).
- [4] Roche Diagnostics. *NGS applications and workflows*. Disponible en: <https://diagnostics.roche.com/global/en/products/product-category/lab-type/sequencing/ngs-applications.html> (Accedido: 26 de abril de 2026).
- [5] Sigma-Aldrich (Merck). *NGS Library Preparation*. Disponible en: <https://www.sigmaaldrich.com/PE/en/products/molecular-biology-and-functional-genomics/ngs-library-prep> (Accedido: 26 de abril de 2026).

- [6] National Human Genome Research Institute. *Nanopore DNA Sequencing*. Disponible en: <https://www.genome.gov/es/genetics-glossary/Nanopore-DNA-Sequencing> (Accedido: 28 de abril de 2026).
- [7] Pacific Biosciences (PacBio). *Informational Guide: Understanding Accuracy in DNA Sequencing*. Disponible en: <https://www.pacb.com/wp-content/uploads/Informational-Guide-Understanding-Accuracy-in-DNA-Sequencing.pdf> (Accedido: 28 de abril de 2026).
- [8] Langmead, B. y Salzberg, S. L. *Bowtie 2 Manual*. Disponible en: <https://bowtie-bio.sourceforge.net/bowtie2/manual.shtml> (Accedido: 28 de abril de 2026).
- [9] National Human Genome Research Institute. *DNA Sequencing Costs: Data*. Disponible en: <https://www.genome.gov/about-genomics/fact-sheets/DNA-Sequencing-Costs-Data> (Accedido: 28 de abril de 2026).