

Matriz BLOSUM45

Johan Fabricio Lizarve Mamani

Edilson Bonet Mamani Yucra

Josue Samuel Philco Puma

Erik Manuel Ramos Quispe

19 de mayo de 2026

1. Introducción

La matriz **BLOSUM45** es una variante de las matrices BLOSUM que está diseñada para detectar similitudes en proteínas evolutivamente muy diferentes. Esta se construye mediante la agrupación de segmentos de proteínas con un umbral de identidad $\geq 45\%$ a partir de bloques de alineamientos locales conservados.

Los puntajes se calculan como log-odds entre la frecuencia observada de sustituciones y la esperada al azar. Entonces, cambios entre aminoácidos conservados obtienen puntajes positivos, mientras que los raros obtienen puntajes negativos. BLOSUM45 penaliza menos las sustituciones que BLOSUM62 o BLOSUM80, lo que permite alineamientos más largos y flexibles entre secuencias débiles. Por esto, BLOSUM45 es útil al comparar proteínas muy distantes (identidad baja, típicamente $< 30\text{--}40\%$) [1].

En la práctica, se utiliza cuando las secuencias son divergentes y otras matrices estándar fallan en la detección de homología lejana [2]. Sus ventajas incluyen mayor sensibilidad (más verdaderos positivos) en la detección de homologías remotas, pero a costa de precisión: aumenta los falsos positivos y alineamientos espurios en regiones poco conservadas [3].

Por ello, BLOSUM45 no conviene para secuencias muy similares (donde BLOSUM80 u otras matrices “estrictas” ofrecen alineamientos más fiables). Al usarse en BLAST u otros alineadores (Smith–Waterman, Needleman–Wunsch), BLOSUM45 tiende a generar alineamientos más largos con *scores* más bajos en regiones conservadas, y es más tolerante con *gaps* y mutaciones [5].

2. Funcionamiento de la matriz BLOSUM45

BLOSUM45 se construye a partir de bloques de alineamientos locales sin *gaps* que representan regiones conservadas de familias de proteínas. El procedimiento que se sigue es el siguiente:

- **Recolección de datos:** Se utiliza una base de datos *BLOCKS* (obtenida con PROTOMAT) con miles de segmentos alineados de proteínas relacionadas.
- **Agrupación por identidades:** Se agrupan todas las secuencias que sean similares dentro de cada bloque. Para la matriz, los segmentos que sean idénticos en $\geq 45\%$ de posiciones colapsan en uno solo, reduciendo el peso de duplicados muy parecidos.
- **Conteo de pares:** Para cada columna del bloque se cuentan todos los pares de aminoácidos (como A–A, A–R, A–N, etc.) presentes. Estos se acumulan en una tabla de frecuencias observadas de pares (210 pares distintos) [1].
- **Cálculo de log-odds:** Se calculan probabilidades observadas (q_{ij}) y esperadas ($p_i p_j$) basadas en frecuencias individuales. Luego, el puntaje de sustitución se define como:

$$s_{ij} = \log_2 \left(\frac{q_{ij}}{p_i p_j} \right)$$

Los valores se escalan (por ejemplo, con un factor 2) y se redondean al entero. Así, si $q_{ij} > p_i p_j$, entonces $s_{ij} > 0$; si es menor, $s_{ij} < 0$.

- **Pares especiales:** Los símbolos B, Z, X y * (como aspartato/glutamato ambiguos) se asignan según D/E u otros valores fijos. También se establecen penalizaciones por *gaps* (por ejemplo, -12 y -4 en Henikoff 1992).

En contraste, BLOSUM45 es muy similar a otros métodos BLOSUM; sin embargo, cambia el umbral de agrupamiento (45 %), produciendo una matriz con baja entropía ($\sim 0,35$ bits por posición), lo que la hace más tolerante a múltiples sustituciones.

3. Proteínas mejor detectadas

Como BLOSUM45 posee un bajo umbral, resulta más sensible para detectar homología en proteínas distantemente relacionadas:

- **Bajas identidades ($\leq 30\text{--}40\%$):** BLOSUM45 tiende a detectar secuencias con alta divergencia evolutiva, donde BLOSUM62 o BLOSUM80 podrían fallar. Es útil, por ejemplo, al comparar proteínas de especies muy diferentes o proteínas que han acumulado muchas mutaciones neutrales.
- **Familias divergentes:** Para familias de proteínas con subunidades distantes o dominios conservados poco evidentes, BLOSUM45 puede ayudar a realinear regiones comunes [3].
- **Ejemplos prácticos:** Algunos estudios de afinidad de tubulinas han utilizado BLOSUM45 con éxito en proteínas con gran divergencia taxonómica. Asimismo, herramientas que analizan proteínas virales o metagenómicas suelen emplear BLOSUM45 para no perder relaciones evolutivas lejanas [2].

En contraste, no es óptima para proteínas casi idénticas o muy similares ($< 60\%$ de divergencia), ya que en estos casos las matrices con números más altos (como BLOSUM62 o BLOSUM80) proporcionan alineamientos más precisos.

4. Cuando usamos BLOSUM45

La matriz **BLOSUM45** se utiliza principalmente cuando se desea encontrar relaciones evolutivas entre proteínas que son muy diferentes entre sí. A diferencia de matrices más estrictas como BLOSUM62 o BLOSUM80, BLOSUM45 permite más cambios entre aminoácidos, lo que la hace útil para detectar similitudes débiles o “lejanas” [4].

Cuando las secuencias tienen baja similitud

BLOSUM45 conviene cuando las proteínas comparadas poseen una identidad de secuencia baja, generalmente menor al 50 %. Esto implica que:

- Las secuencias han acumulado muchas mutaciones.
- Hay menos aminoácidos iguales entre ellas.
- La relación evolutiva es más difícil de detectar.

Las matrices más estrictas pueden considerar estas diferencias como demasiado grandes y no encontrar alineamientos significativos. En cambio, BLOSUM45 es más tolerante y permite detectar homología remota [4].

Cuando BLAST devuelve pocos resultados

Herramientas como BLAST utilizan por defecto BLOSUM62, ya que ofrece un equilibrio entre sensibilidad y precisión. Sin embargo, pueden ocurrir situaciones como:

- El alineamiento es muy corto.
- Hay pocos *hits*.
- El *score* es bajo.

En algunos casos, las proteínas podrían estar biológicamente relacionadas. Cambiar la matriz a BLOSUM45 puede ayudar porque:

- Reduce la penalización por sustituciones.
- Permite más diferencias entre aminoácidos.
- Extiende alineamientos débiles.

Importancia de la longitud de la secuencia

BLOSUM45 puede funcionar mejor con alineamientos largos. Sin embargo, al permitir más diferencias, también aumenta el riesgo de coincidencias por azar [4]. En secuencias cortas:

- El ruido estadístico es mayor.
- Pueden aparecer falsos positivos.
- Los alineamientos pueden parecer similares sin ser realmente homólogos.

Por ello:

- Para dominios pequeños o proteínas cortas se prefieren matrices como BLOSUM50 o BLOSUM62.
- BLOSUM45 es más útil cuando existen regiones largas parcialmente conservadas.

5. Ventajas y Limitaciones

Ventajas de BLOSUM45

- **Mayor sensibilidad (recuperación de homologías remotas):** Permite detectar familias de proteínas con baja identidad que otras matrices pueden pasar por alto, reduciendo los falsos negativos entre secuencias distantes [2].
- **Alineamientos más largos:** Al tolerar más *mismatches* o mutaciones, permite alinear segmentos más extensos y puede revelar dominios conservados poco evidentes.
- **Descubrimiento evolutivo:** Es útil en estudios filogenéticos profundos o en el análisis de genomas con bajo apareamiento (por ejemplo, virus o microbiomas), donde las proteínas han divergido considerablemente.

Limitaciones de BLOSUM45

- **Menor especificidad:** Al relajar los requisitos de coincidencia, incrementa los falsos positivos. Pueden aparecer alineamientos entre regiones que no son realmente homólogas (sobreextensión del alineamiento) [3].
- **Puntajes más bajos o neutros:** El *score* global puede ser menor en comparación con BLOSUM62, lo que dificulta distinguir entre señales reales y ruido de fondo.
- **No adecuado para secuencias similares:** En casos de alta identidad, BLOSUM45 puede no penalizar lo suficiente las diferencias, produciendo alineamientos subóptimos. En estos casos es preferible utilizar matrices como BLOSUM62 o BLOSUM80 [2].
- **Dependencia de penalizaciones de *gap*:** Dado que BLOSUM45 favorece alineamientos más extensos, la elección de los costos de apertura y extensión de *gaps* es crítica. Penalizaciones inadecuadas pueden inflar alineamientos irrelevantes.

6. Impacto en los resultados del alineamiento

Al cambiar la matriz de *scoring*, los alineamientos obtenidos pueden variar significativamente. A continuación se muestran algunos efectos en herramientas como BLAST y algoritmos de programación dinámica (Smith–Waterman, Needleman–Wunsch):

Scores totales

Con BLOSUM45, las coincidencias no exactas reciben un mejor *score* relativo. Consideremos un ejemplo sencillo de alineamiento global sin *gaps* entre secuencias cortas:

Secuencia 1 = AC

Secuencia 2 = AT

Usando BLOSUM45 (con penalidades de *gap* arbitrarias, por ejemplo apertura 10 y extensión 1):

- A-A: puntaje +5
- C-T: puntaje -1

$$\text{Score total} \approx 5 + (-1) = 4$$

Con BLOSUM62 (mismas condiciones):

- A-A: +4
- C-T: -2

$$\text{Score} \approx 4 + (-2) = 2$$

Así, BLOSUM45 produce un *score* mayor para el mismo alineamiento, reflejando una mayor tolerancia a sustituciones como $C \rightarrow T$.

Longitud del alineamiento

BLOSUM45 tiende a generar alineamientos más largos antes de detenerse, ya que los puntajes de *mismatches* permiten extender el alineamiento. En Smith-Waterman, esto puede resultar en alineamientos locales más extensos y valores E más altos (menos significativos) en comparación con BLOSUM62. En Needleman-Wunsch, las extensiones de *gap* pueden ser aceptadas con mayor frecuencia si la matriz compensa el costo.

Penalización de *gaps*

Dado que BLOSUM45 es más permisiva con sustituciones, un *gap* representa una penalización relativa menor frente a reemplazos. Con parámetros típicos (apertura 10, extensión 1), BLOSUM45 puede aceptar inserciones o deleciones más largas sin reducir drásticamente el *score*, mientras que BLOSUM62 tendería a penalizarlas más severamente.

Resultados en BLAST

Al utilizar BLASTP con BLOSUM45, generalmente se obtienen más *hits* (mayor cobertura), pero con *scores* más bajos en regiones conservadas. Esto incrementa el riesgo de coincidencias espurias, por lo que suele ser necesario aplicar filtros más estrictos (por ejemplo, valores E más bajos) o realizar análisis adicionales de validación.

Referencias

- [1] Henikoff, S., and Henikoff, J. G. *Amino acid substitution matrices from protein blocks*. Proceedings of the National Academy of Sciences of the United States of America, vol. 89, no. 22, pp. 10915–10919, 1992. Disponible en: <https://doi.org/10.1073/pnas.89.22.10915>
- [2] QIAGEN Digital Insights. *BE Scoring matrices*. CLC Genomics Workbench Manual. Disponible en: https://resources.qiagenbioinformatics.com/manuals/clcgenomicsworkbench/755/index.php?manual=BE_Scoring_matrices.html

- [3] Pearson, W. R. *Selecting the Right Similarity-Scoring Matrix*. Current Protocols in Bioinformatics, vol. 43, pp. 3.5.1–3.5.9, 2013. doi: <https://doi.org/10.1002/0471250953.bi0305s43>
- [4] National Center for Biotechnology Information (NCBI). *Substitution Matrices*. Disponible en: https://blast.ncbi.nlm.nih.gov/html/sub_matrix.html
- [5] National Center for Biotechnology Information (NCBI). *BLAST scores*. National Library of Medicine. Disponible en: https://www.nlm.nih.gov/ncbi/workshops/2023-08_BLAST_evol/blast_score.html
- [6] Kennard, A. S., Velle, K. B., Ranjan, R., Schulz, D., and Fritz-Laylin, L. K. *Tubulin sequence divergence is associated with the use of distinct microtubule regulators*. Current Biology, 2024. doi: <https://doi.org/10.1016/j.cub.2024.11.022>