




Matriz BLOSUM45

Detección de homología remota en proteínas

- Lizarve Mamani, Johan Fabricio
- Mamani Yucra, Edilson Bonet
- Philco Puma, Josue Samuel
- Ramos Quispe, Erik Manuel

¿Qué es BLOSUM45?

Variante de Alta Sensibilidad

Variante de las matrices BLOSUM construida agrupando segmentos de proteínas con identidad $\geq 45\%$. Es una matriz de sustitución diseñada para detectar **similitudes en secuencias evolutivamente distantes**, capturando relaciones que otras matrices ignoran.



Umbral de Agrupamiento

$\geq 45\%$ de identidad

Las secuencias con esta similitud o más se colapsan en una sola para **reducir el sesgo** de datos redundantes en la base de datos BLOCKS.




Puntajes Log-Odds

Basado en **probabilidades estadísticas**.

Compara la frecuencia observada de pares de aminoácidos contra lo que se esperaría por azar, asignando valores más altos a sustituciones conservadas biológicamente.

↘ **Menor umbral → Mayor tolerancia a mutaciones**

Cómo funciona la matriz



Reduccion $\leq 45\%$ del dataset BLOCK

- Inicio:
k = N secuencias individuales
- Mientras existan dos secuencias (o grupos) con identidad $> N\%$:
 - Agruparlas en un nuevo grupo
- Fin: Cuando todos los pares de grupos tengan identidad $\leq N\%$

El número N es el límite máximo de identidad que se permite entre los grupos finales.

- IDENTIDAD entre dos secuencias:
 - $= (\text{coincidencias} / \text{longitud del bloque}) \times 100$
- IDENTIDAD entre dos grupos:
 - = máxima identidad entre cualquier par (una de cada grupo)
- CONDICIÓN DE PARADA para BLOSUM N:
 - Todas las identidades entre grupos $\leq N\%$

	C1	C2	C3	C4
S1	A	V	L	M
S2	A	V	L	M
S3	A	V	L	M
S4	A	I	I	M
S5	A	I	I	W

$$a_{ij} = \left(\frac{1}{\lambda} \right) \log \left(\frac{p_{ij}}{q_i * q_j} \right)$$

- **a:** Es el valor entero final que se coloca en el casillero de la matriz para el cruce del aminoácido i con el j.
- **1/lambda:** Asegura que, tras su aplicación y redondeo, la matriz contenga valores enteros dispersos y fáciles de procesar.
- **p (Probabilidad de Reemplazo):** Probabilidad real observada de que los aminoácidos i y j se intercambien o reemplacen uno al otro en una secuencia homóloga.
- **q(Probabilidades Aleatorias):** Probabilidades individuales de encontrar los aminoácidos i y j en cualquier secuencia de proteína de forma totalmente aleatoria. Su multiplicación ($q_i q_j$) representa el comportamiento del azar.

The BLOSUM45 Matrix

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	5	-2	-1	-2	-1	-1	-1	0	-2	-1	-1	-1	-1	-2	-1	1	0	-2	-2	0
R	-2	7	0	-1	-3	1	0	-2	0	-3	-2	3	-1	-2	-2	-1	-1	-2	-1	-2
N	-1	0	6	2	-2	0	0	0	1	-2	-3	0	-2	-2	-2	1	0	-4	-2	-3
D	-2	-1	2	7	-3	0	2	-1	0	-4	-3	0	-3	-4	-1	0	-1	-4	-2	-3
C	-1	-3	-2	-3	12	-3	-3	-3	-3	-3	-2	-3	-2	-2	-4	-1	-1	-5	-3	-1
Q	-1	1	0	0	-3	6	2	-2	1	-2	-2	1	0	-4	-1	0	-1	-2	-1	-3
E	-1	0	0	2	-3	2	6	-2	0	-3	-2	1	-2	-3	0	0	-1	-3	-2	-3
G	0	-2	0	-1	-3	-2	-2	7	-2	-4	-3	-2	-2	-3	-2	0	-2	-2	-3	-3
H	-2	0	1	0	-3	1	0	-2	10	-3	-2	-1	0	-2	-2	-1	-2	-3	2	-3
I	-1	-3	-2	-4	-3	-2	-3	-4	-3	5	2	-3	2	0	-2	-2	-1	-2	0	3
L	-1	-2	-3	-3	-2	-2	-2	-3	-2	2	5	-3	2	1	-3	-3	-1	-2	0	1
K	-1	3	0	0	-3	1	1	-2	-1	-3	-3	5	-1	-3	-1	-1	-1	-2	-1	-2
M	-1	-1	-2	-3	-2	0	-2	-2	0	2	2	-1	6	0	-2	-2	-1	-2	0	1
F	-2	-2	-2	-4	-2	-4	-3	-3	-2	0	1	-3	0	8	-3	-2	-1	1	3	0
P	-1	-2	-2	-1	-4	-1	0	-2	-2	-2	-3	-1	-2	-3	9	-1	-1	-3	-3	-3
S	1	-1	1	0	-1	0	0	0	-1	-2	-3	-1	-2	-2	-1	4	2	-4	-2	-1
T	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-1	-1	2	5	-3	-1	0
W	-2	-2	-4	-4	-5	-2	-3	-2	-3	-2	-2	-2	-2	1	-3	-4	-3	15	3	-3
Y	-2	-1	-2	-2	-3	-1	-2	-3	2	0	0	-1	0	3	-3	-2	-1	3	8	-1
V	0	-2	-3	-3	-1	-3	-3	-3	-3	3	1	-2	1	0	-3	-1	0	-3	-1	5

Proteínas que detecta mejor

BLOSUM45 es óptima cuando las secuencias tienen BAJA identidad ($\leq 45\%$)



Divergencia Alta

Proteínas con mucha acumulación de mutaciones neutras, donde matrices como BLOSUM62 fallarían en detectar homología.



Dominios Lejanos

Subunidades muy distantes de una familia, permitiendo realinear regiones conservadas estructuralmente poco evidentes.



Análisis Viral

Ideal para secuencias de microbiomas poco caracterizados y genomas virales con profunda divergencia evolutiva.

¿Cuándo conviene usarla?

Úsala cuando...

- La identidad de secuencia estimada es **menor al 50%**.
- BLAST devuelve pocos hits o E-values marginales al usar la matriz por defecto (BLOSUM62).
- Las secuencias tienen una divergencia evolutiva muy profunda.
- Existen regiones largas parcialmente conservadas.

Evítala cuando...

- Las secuencias son muy similares (**>60–80% identidad**)
→ usar BLOSUM80.
- Las proteínas son muy cortas o se evalúan dominios pequeños.
- Se requiere altísima especificidad para minimizar falsos positivos.
- Se trabaja con alineamientos locales estrictos.

Ventajas y Limitaciones de BLOSUM45

Ventajas

- **Mayor sensibilidad:** Detecta familias con baja identidad que otras matrices pasan por alto. Reduce los falsos negativos entre secuencias distantes.
- **Alineamientos más largos:** Permite alinear segmentos más extensos al tolerar más mismatches. Revela dominios conservados poco evidentes.
- **Descubrimiento evolutivo:** Útil en estudios filogenéticos profundos, análisis de virus y microbiomas con proteínas muy divergentes.

Limitaciones

- **Menor especificidad:** Incrementa falsos positivos y alineamientos supuestos en regiones no homólogas.
- **Puntajes bajos:** Menos claro el contraste frente al ruido de fondo comparado con BLOSUM62.
- **No apto para secuencias similares:** En alta identidad (>60%), use BLOSUM80/62 para evitar resultados subóptimos.
- **Dependencia de Gaps:** Los costos de apertura/extensión son críticos para evitar inflar alineamientos irrelevantes.

Impacto en Alineamientos

Comparación práctica de penalizaciones sin gaps: BLOSUM45 vs BLOSUM62

Par evaluado	Score BLOSUM45	Score BLOSUM62	Impacto resultante
A – A (Match exacto)	+ 5	+ 4	BLOSUM45 es más generoso premiando matches directos.
C – T (Mismatch)	- 1	- 2	Al penalizar menos la sustitución, evita que el alineamiento se corte prematuramente.
Score Total (AC vs AT)	4	2	BLOSUM45 acumula un score significativamente mayor para secuencias divergentes.

Conclusiones Clave

El equilibrio entre sensibilidad y especificidad

BLOSUM45 se consolida como la herramienta de elección en bioinformática para rescatar homología profunda que matrices estándar no logran vislumbrar.

Alcance Óptimo

Ideal para identidad del 30–40%.



Extensiones Largas

Fuerza extensiones largas en BLAST y Smith-Waterman.



Control de Calidad

Requiere evaluación crítica de los falsos positivos.